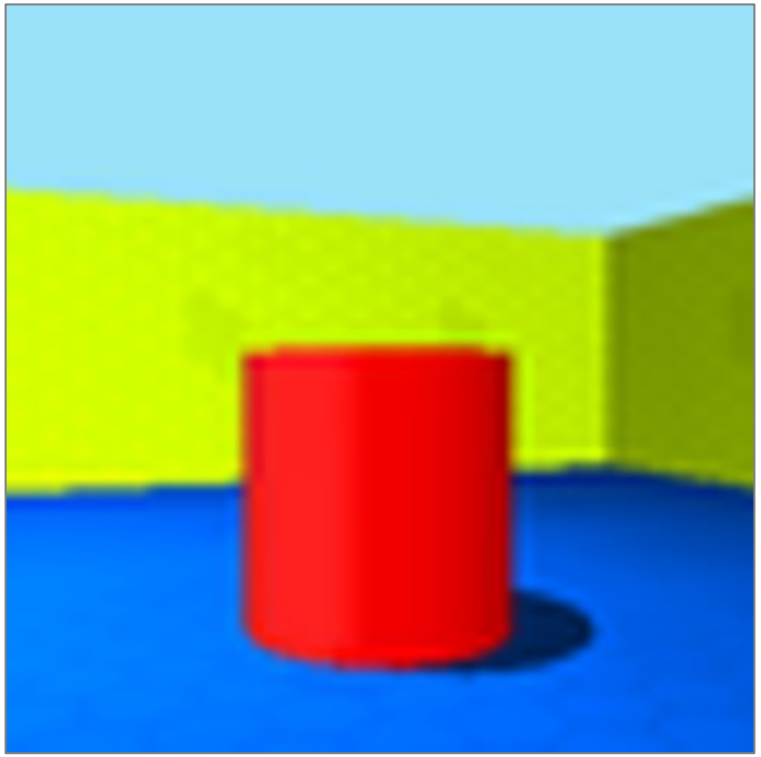
실험 과제: 물체의 모양 · 색 · 크기 분류

데이터: 3D-Shapes (방 안에 물체 하나가 놓인 64x64 이미지, 정답이 명확함)

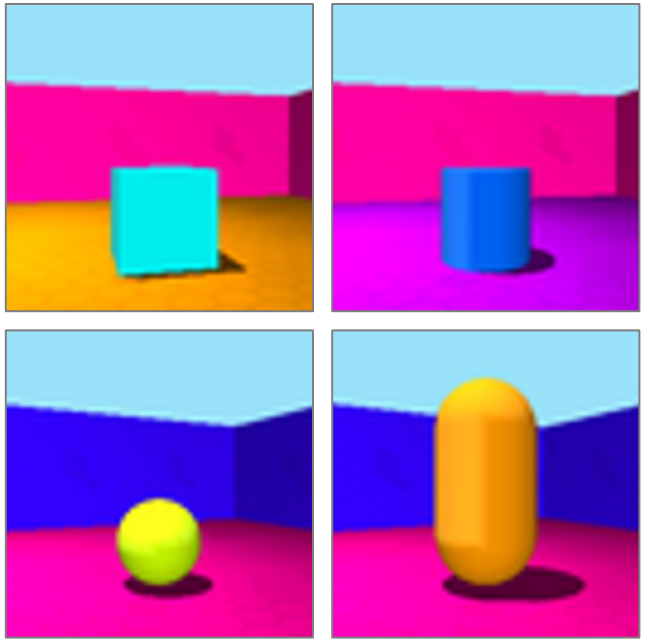


모양 **원기둥**

색 **빨강**

크기 **8단계 중 6**

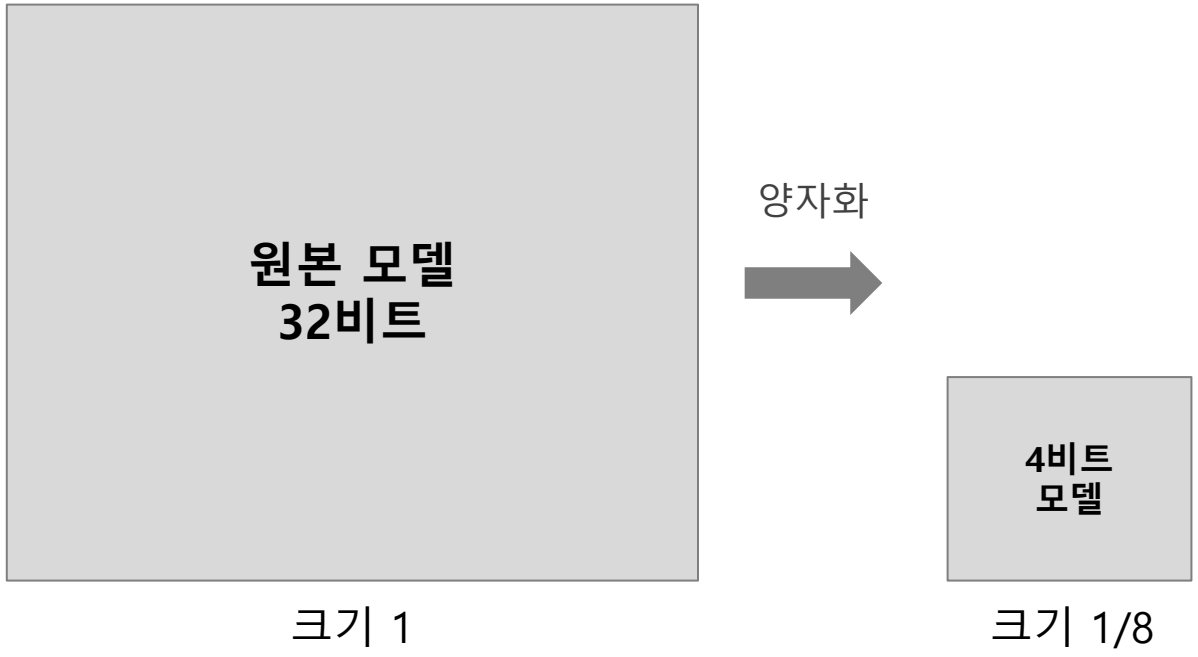
다른 예시



원본 모델 정확도 100% (학습에 사용하지 않은 이미지 1만 장)

양자화 목적: 정확도를 유지하면서 모델 크기 축소

원본 모델은 숫자 하나를 32비트로 저장. 비트 수를 줄이면 모델 크기 감소



필요성 **스마트폰 · 소형 기기 탑재**

문제점 **비트 수를 지나치게 줄이면 정확도 하락 (100% → 58%)**

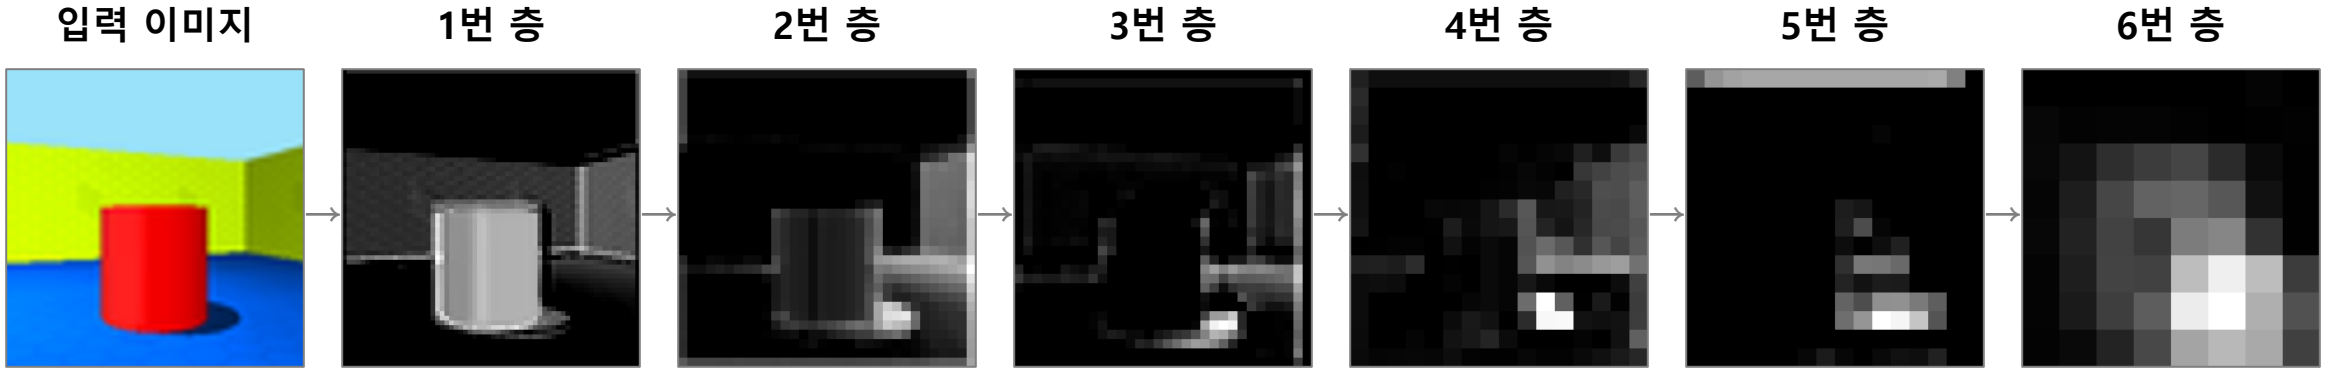
연구 질문 **어느 층의 비트 수를 유지해야 하는가**

원본 모델 정확도가 100%이므로, 이후의 오답은 모두 양자화의 영향

목표: 모델 크기 축소 + 정확도 유지 → 층별 중요도 파악 필요

모델 구조: 6개 층을 순서대로 통과

각 층은 앞 층의 출력을 받아 특징을 추출하고 다음 층으로 전달



1 · 2번 층	3 · 4번 층	5 · 6번 층
물체 윤곽이 뚜렷함	해상도 감소, 형태가 흐려짐	압축된 요약 정보

흑백 이미지: 각 층의 출력(특징 맵, feature map). 실제 모델에서 추출, 밝을수록 큰 값. 6번 층 출력으로 최종 예측

앞쪽 층: 세부 형태 유지 / 뒤쪽 층: 요약 정보

양자화: 숫자를 더 적은 단계로 표현

예: 키 173.4cm를 170cm로 기록. 저장 공간은 줄고 세부 값은 사라짐

원본 (32비트): 연속에 가까움

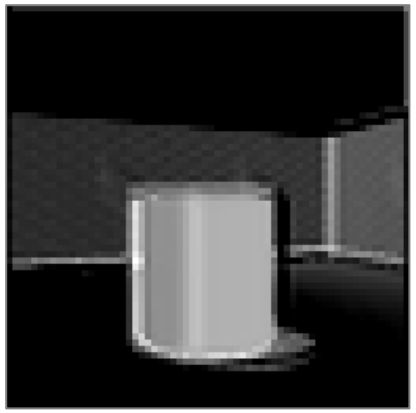


8비트: 256단계



4비트: 16단계





1번 층 출력 (원본)

→



4비트 양자화 후

장점

모델 크기 1/8 (4비트 기준)

단점

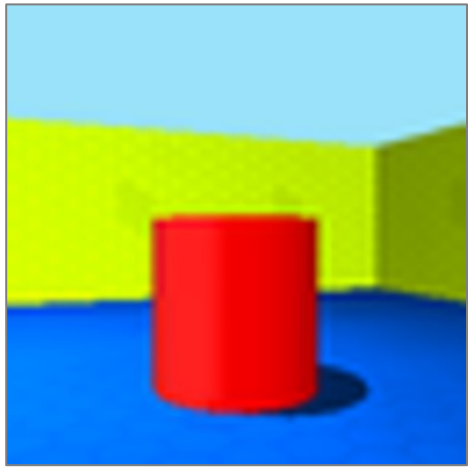
비슷한 값들이 하나의 값으로 합쳐짐

모델 크기는 감소, 내부 값에는 오차 발생 → 정확도 영향 확인 필요

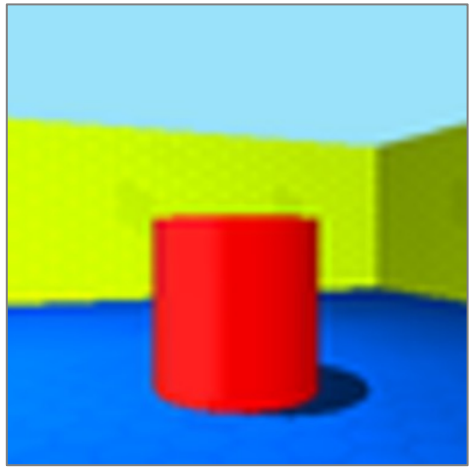
결과: 8비트는 정확도 유지, 4비트는 오답 발생

같은 이미지를 원본 · 8비트 · 4비트 모델에 입력

입력 이미지



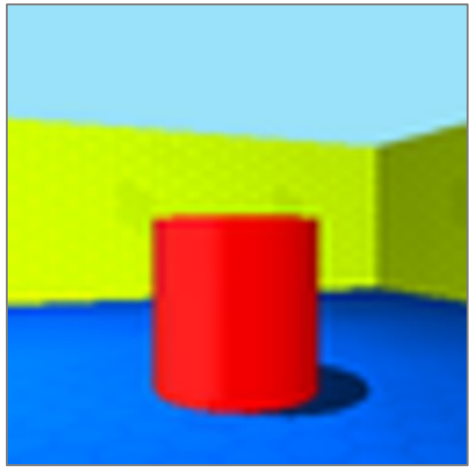
원본 모델



빨간 원기둥 (정답)

정확도 **100%**

8비트 모델



빨간 원기둥 (정답)

정확도 **100%**

4비트 모델



노란 캡슐 (오답)

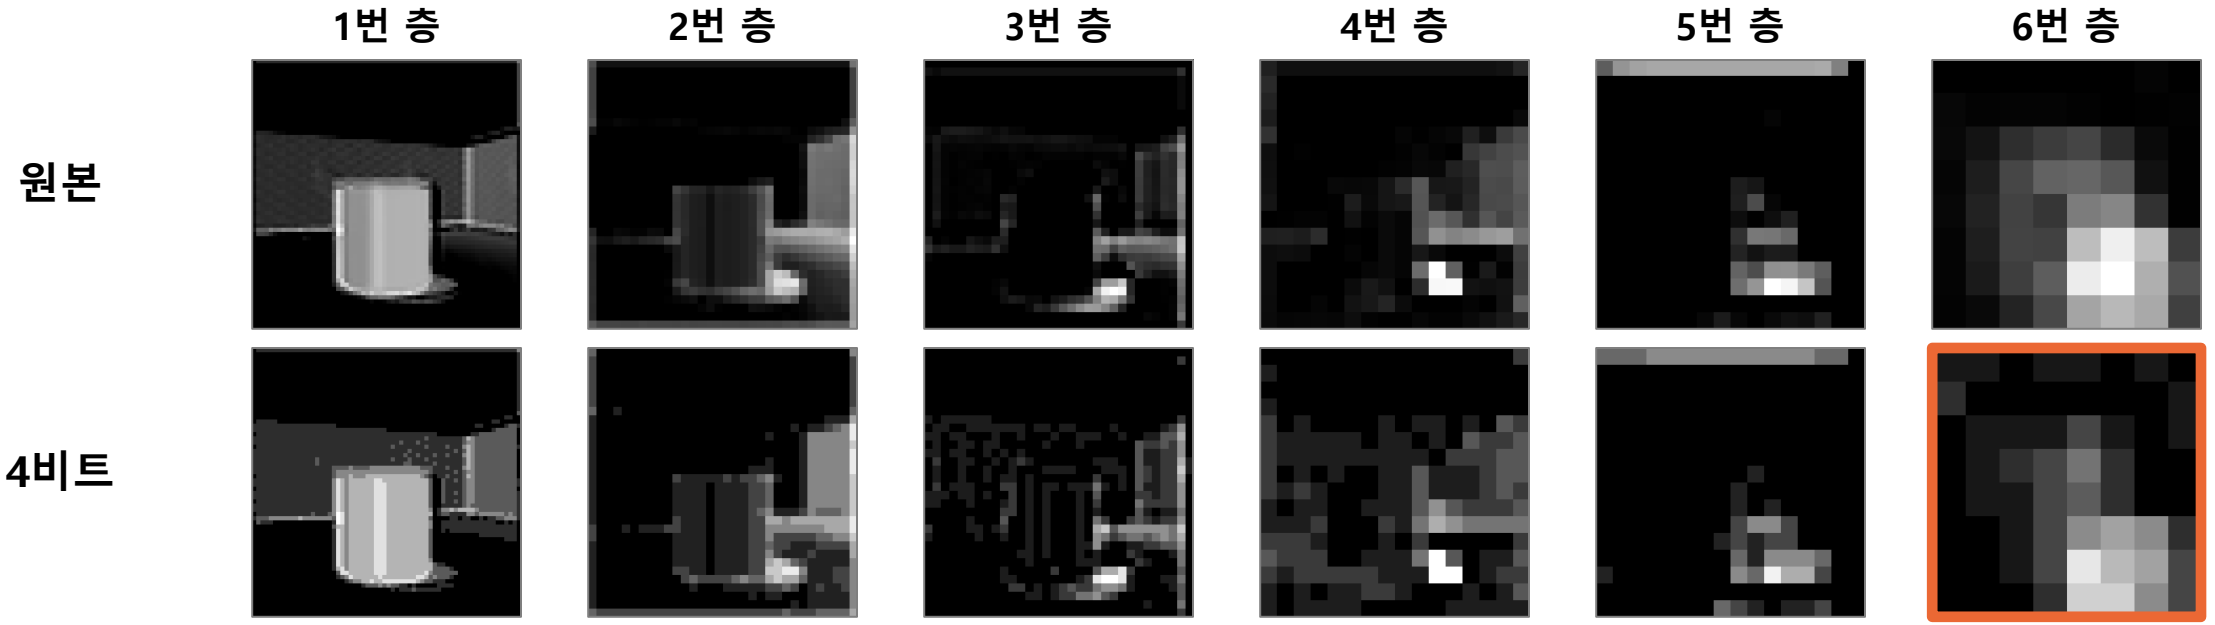
정확도 **58%**

모델 칸의 이미지: 모델의 예측에 해당하는 데이터셋 이미지. 6비트 100%, 5비트 98.7%

4비트 모델: 빨간 원기둥을 노란 캡슐로 예측. 정확도 100% → 58%

층별 오차: 6번 층에서 가장 큼

각 층의 출력을 원본 모델과 4비트 모델에서 비교





오차가 가장 큰 층: 6번 층 → 정확도 하락의 원인으로 예상

확인 방법: 한 층만 원본 값으로 복원

재학습 없이 해당 층의 값만 양자화 이전 값으로 교체. 나머지 층은 4비트 유지



목적 **해당 층 복원 시 정확도가 회복되는지 확인 (층별 영향 진단)**

특정 층 복원 시 정확도 회복 → 정확도에 중요한 층

복원 결과: 효과가 큰 층은 6번이 아닌 1번 층

4비트 모델에서 한 층만 복원한 뒤 같은 이미지를 다시 입력

전체 4비트



노란 캡슐 (오답)

정확도 58%

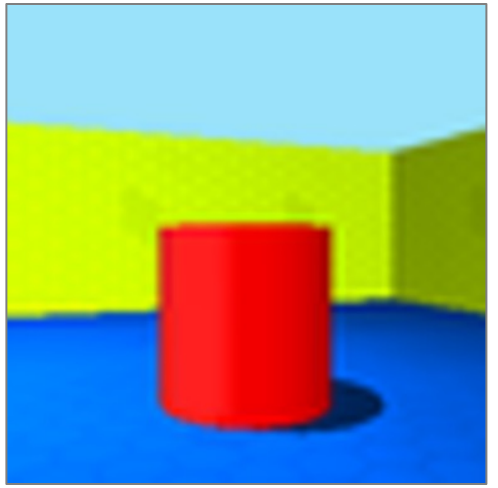
6번 층만 복원



노란 캡슐 (오답 유지)

정확도 변화 -0.5%p

1번 층만 복원



빨간 원기둥 (정답)

정확도 변화 +19.2%p

활용 예: 1번 층만 8비트로 저장 시 모델 크기 약 0.6% 증가, 정확도 58% → 74%

이미지는 예시 1장(모델 1개), 정확도는 모델 5개 평균

오차가 큰 층 ≠ 복원 효과가 큰 층